第九章 EM 算法及其推广

袁春 清华大学深圳研究生院 李航 华为诺亚方舟实验室

目录

- 1. EM 算法的引入
- 2. EM 算法的收敛性
- 3. EM 算法在高斯混合模型学习中的应用
- 4. EM 算法的推广

EM 算法的引入

- ≫EM 算法
- ∞EM 算法的导出
- ∞EM 算法在非监督学习中的应用

三硬币模型

- ∞三硬币模型: 硬币A、B、C, 正面概率π, p, q,
- ∞A正面时选B, 反面选C,
- ≥>得到结果: 1101001011
- ∞问题: 只能看结果,不能看中间过程,估算π, p, q,
- ₩解:模型

$$P(y \mid \theta) = \sum_{z} P(y, z \mid \theta) = \sum_{z} P(z \mid \theta) P(y \mid z, \theta)$$
$$= \pi p^{y} (1 - p)^{1 - y} + (1 - \pi) q^{y} (1 - q)^{1 - y}$$

№随机变量Y是观测变量,表示一次试验观测的结果是1或 o,随机变量z是隐变量,表示未观测到的掷硬币A的结 果,这一模型是以上数据的生成模型。

三硬币模型

∞观测数据:
$$Y = (Y_1, Y_2, \dots, Y_n)^T$$

≫未观测数据:
$$Z = (Z_1, Z_2, \dots, Z_n)^T$$

必似然函数:
$$P(Y|\theta) = \sum_{z} P(Z|\theta)P(Y|Z,\theta)$$

$$\mathbb{E}[\mathbb{I}: P(Y|\theta) = \prod_{j=1}^{n} [\pi p^{y_j} (1-p)^{1-y_j} + (1-\pi)q^{y_j} (1-q)^{1-y_j}]$$

∞极大似然估计:

$$\hat{\theta} = \arg\max_{\theta} \log P(Y \mid \theta)$$

∞该问题没有解析解,EM迭代法:

≫选取初值:
$$\theta^{(0)} = (\pi^{(0)}, p^{(0)}, q^{(0)})$$

- 第i步的估计值: $\theta^{(i)} = (\pi^{(i)}, p^{(i)}, q^{(i)})$
- ∞EM算法第i+1次迭代:
- Σ E步: 计算在模型参数 $\pi^{(i)}$, $p^{(i)}$, $q^{(i)}$ 下观测数据yi来自掷硬币B的概率:

$$\mu^{(i+1)} = \frac{\pi^{(i)}(p^{(i)})^{y_j}(1-p^{(i)})^{1-y_j}}{\pi^{(i)}(p^{(i)})^{y_j}(1-p^{(i)})^{1-y_j} + (1-\pi^{(i)})(q^{(i)})^{y_j}(1-q^{(i)})^{1-y_j}}$$

∞M步: 计算模型参数的新估计值

$$\pi^{(i+1)} = \frac{1}{n} \sum_{j=1}^{n} \mu_{j}^{(i+1)} \qquad p^{(i+1)} = \frac{\sum_{j=1}^{n} \mu_{j}^{(i+1)} y_{j}}{\sum_{j=1}^{n} \mu_{j}^{(i+1)}} \qquad q^{(i+1)} = \frac{\sum_{j=1}^{n} (1 - \mu_{j}^{(i+1)}) y_{j}}{\sum_{j=1}^{n} (1 - \mu_{j}^{(i+1)})}$$

初值:

$$\pi^{(0)} = 0.5$$
, $p^{(0)} = 0.5$, $q^{(0)} = 0.5$

对
$$y_j = 1$$
 与 $y_j = 0$ 均有 $\mu_j^{(1)} = 0.5$

利用迭代公式,得: $\pi^{(1)} = 0.5$, $p^{(1)} = 0.6$, $q^{(1)} = 0.6$

$$\mu_j^{(2)} = 0.5$$
, $j = 1, 2, \dots, 10$

继续迭代,得:

$$\pi^{(2)} = 0.5$$
, $p^{(2)} = 0.6$, $q^{(2)} = 0.6$

得到模型参数的极大似然估计:

$$\hat{\pi} = 0.5$$
, $\hat{p} = 0.6$, $\hat{q} = 0.6$

如果取初值:

$$\pi^{(0)} = 0.4$$
, $p^{(0)} = 0.6$, $q^{(0)} = 0.7$

$$\hat{\pi} = 0.4064$$
, $\hat{p} = 0.5368$, $\hat{q} = 0.6432$

完全数据 complete-data $P(Y,Z|\theta)$

不完全数据 incomplete-data $P(Y | \theta)$

输入:观测变量数据Y,隐变量数据Z,联合分布P(Y,Z|Θ)

条件分布 $P(Z|Y,\Theta)$

输出:模型参数Θ

- (1) 选择参数的初值 $\theta^{(0)}$, 开始迭代;
- (2) E步: 记 $\theta^{(i)}$ 为第i次迭代参数 θ 的估计值,

在第i+1次迭代的E步, 计算

$$Q(\theta, \theta^{(i)}) = E_{Z}[\log P(Y, Z \mid \theta) \mid Y, \theta^{(i)}]$$
$$= \sum_{Z} \log P(Y, Z \mid \theta) P(Z \mid Y, \theta^{(i)})$$

给定观测数据Y和当前参数估计Θ

(3) M步: 求使 $Q(\theta, \theta^{(i)})$ 极大化的 θ ,

确定第i+1次迭代的参数的估计值 $\theta^{(i+1)}$

$$\theta^{(i+1)} = \arg\max_{\theta} Q(\theta, \theta^{(i)})$$

Q函数定义:

完全数据的对数似然函数logP(Y,Z|Θ)关于在给定观测数据Y和当前函数Θ⁽ⁱ⁾下对未观测数据Z的条件概率分布P(Z|Y,Θ⁽ⁱ⁾),的期望称为Q函数,即:

$$Q(\theta, \theta^{(i)}) = E_Z[\log P(Y, Z \mid \theta) \mid Y, \theta^{(i)}]$$

- ∞算法说明:
- ≫步骤3,完成一次迭代: Θ⁽ⁱ⁾到Θ⁽ⁱ⁺¹⁾,将证明每次迭代使似然函数增大或达到局部最大值。
- 步骤4,停止迭代的条件 $\|\boldsymbol{\theta}^{(i+1)} \boldsymbol{\theta}^{(i)}\| \le \boldsymbol{\varepsilon}_1$ 或 $\|\boldsymbol{Q}(\boldsymbol{\theta}^{(i+1)}, \boldsymbol{\theta}^{(i)}) \boldsymbol{Q}(\boldsymbol{\theta}^{(i)}, \boldsymbol{\theta}^{(i)}) \| \le \boldsymbol{\varepsilon}_2$

≫为什么EM算法能近似实现对观测数据的极大似然估计?

≫极大化(不
$$L(\theta) = \log P(Y | \theta) = \log \sum_{z} P(Y, Z | \theta)$$
)。函数:

$$= \log \left(\sum_{Z} P(Y \mid Z, \theta) P(Z \mid \theta) \right)$$

∞难点:有未观测数据,包含和的对数。

EM通过迭代逐步近似极大U(Ω),希望 $L(\theta) > L(\theta'')$

∞考虑二者的差:

$$L(\theta) - L(\theta^{(i)}) = \log \left(\sum_{Z} P(Y \mid Z, \theta) P(Z \mid \theta) \right) - \log P(Y \mid \theta^{(i)})$$

≫Jason不等式:

$$L(\theta) - L(\theta^{(i)}) = \log \left(\sum_{Z} P(Y|Z, \theta^{(i)}) \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Y|Z, \theta^{(i)})} \right) - \log P(Y|\theta^{(i)})$$

$$\geq \sum_{Z} P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})} - \log P(Y|\theta^{(i)})$$

$$= \sum_{Z} P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})P(Y|\theta^{(i)})}$$

:\$\columbf{\omega}\$

$$B(\theta, \theta^{(i)}) \triangleq L(\theta^{(i)}) + \sum_{Z} P(Z \mid Y, \theta^{(i)}) \log \frac{P(Y \mid Z, \theta) P(Z \mid \theta)}{P(Z \mid Y, \theta^{(i)}) P(Y \mid \theta^{(i)})}$$

>>则:

$$L(\theta) \ge B(\theta, \theta^{(i)})$$

$$L(\boldsymbol{\theta}^{(i)}) = B(\boldsymbol{\theta}^{(i)}, \boldsymbol{\theta}^{(i)})$$

任何可以使 $B(\theta, \theta^{(i)})$ 增大的 θ ,也可以使 $L(\theta)$ 增大

∞选择:

$$\theta^{(i+1)} = \arg\max_{\theta} B(\theta, \theta^{(i)})$$

∞省去和 Θ 无关的项:

$$\theta^{(i+1)} = \arg \max_{\theta} \left(L(\theta^{(i)}) + \sum_{Z} P(Z \mid Y, \theta^{(i)}) \log \frac{P(Y \mid Z, \theta) P(Z \mid \theta)}{P(Z \mid Y, \theta^{(i)}) P(Y \mid \theta^{(i)})} \right)$$

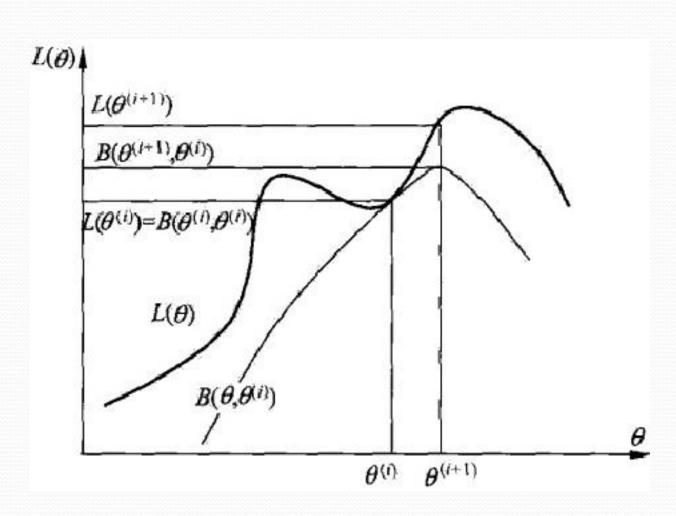
$$= \arg \max_{\theta} \left(\sum_{Z} P(Z \mid Y, \theta^{(i)}) \log(P(Y \mid Z, \theta) P(Z \mid \theta)) \right)$$

$$= \arg \max_{\theta} \left(\sum_{Z} P(Z \mid Y, \theta^{(i)}) \log P(Y, Z \mid \theta) \right)$$

$$= \arg \max_{\theta} Q(\theta, \theta^{(i)})$$

EM算法的解释

L(Θ)开始



EM在非监督学习中的应用

≥> 生成模型由联合概率分布P(X,Y)表示,可以认为非监督 学习训练数据是联合概率分布产生的数据,X为观测数 据,Y为未观测数据。

- ≥EM,提供一种近似计算含有隐变量概率模型的极大似然估计的方法,
- ∞EM, 最大优点: 简单性和普适性;
- ₩疑问:
- ∞1、EM算法得到的估计序列是否收敛?
- №2、如果收敛,是否是全局极大值或局部极大值?

- ∞两个收敛定理:
- 定理9.1: 设 $P(Y|\Theta)$ 为观测数据的似然函数, $Θ^{(i)}(i=1,2...)$ 为EM参数估计序列, $P(Y|\Theta^{(i)})$ (i=1,2,...)为对应的似然函数序列,则 $P(Y|\Theta^{(i)})$ 是单调递增的,即:

$$P(Y | \boldsymbol{\theta}^{(i+1)}) \ge P(Y | \boldsymbol{\theta}^{(i)})$$

∞证明:由

$$P(Y | \theta) = \frac{P(Y, Z | \theta)}{P(Z | Y, \theta)}$$

$$\log P(Y \mid \theta) = \log P(Y, Z \mid \theta) - \log P(Z \mid Y, \theta)$$

$$\Leftrightarrow : H(\theta, \theta^{(i)}) = \sum_{Z} \log P(Z \mid Y, \theta) P(Z \mid Y, \theta^{(i)})$$

>>则:

$$\log P(Y \mid \boldsymbol{\theta}) = Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{(i)}) - H(\boldsymbol{\theta}, \boldsymbol{\theta}^{(i)})$$

₩得:

$$\log P(Y|\theta^{(i+1)}) - \log P(Y|\theta^{(i)})$$
= $[Q(\theta^{(i+1)}, \theta^{(i)}) - Q(\theta^{(i)}, \theta^{(i)})] - [H(\theta^{(i+1)}, \theta^{(i)}) - H(\theta^{(i)}, \theta^{(i)})]$

∞只需证右端非负

∞前半部分, Θ(i+1)为极大值, 所以

$$Q(\boldsymbol{\theta}^{(i+1)}, \boldsymbol{\theta}^{(i)}) - Q(\boldsymbol{\theta}^{(i)}, \boldsymbol{\theta}^{(i)}) \ge 0$$

∞后半部分:

$$H(\theta^{(i+1)}, \theta^{(i)}) - H(\theta^{(i)}, \theta^{(i)})$$

$$= \sum_{Z} \left(\log \frac{P(Z \mid Y, \theta^{(i+1)})}{P(Z \mid Y, \theta^{(i)})} \right) P(Z \mid Y, \theta^{(i)})$$

$$\leq \log \left(\sum_{Z} \frac{P(Z \mid Y, \theta^{(i+1)})}{P(Z \mid Y, \theta^{(i)})} P(Z \mid Y, \theta^{(i)}) \right)$$

$$= \log P(Z \mid Y, \theta^{(i+1)}) = 0$$

- ≫定理9.2:
- 验设L(Θ)=logP(Y|Θ),为观测数据的对数似然函数,Θ (i)(i=1,2...) 为EM算法得到的参数估计序列, $L(Θ^{(i)})$ 为对 应的对数似然函数序列,
- **№1**、如果P(Y|Θ)有上界,则L(Θ⁽ⁱ⁾) =logP(Y|Θ⁽ⁱ⁾)收敛到某一值L*;
- ≥2、在函数Q(Θ,Θ')与L(Θ)满足一定条件下,由EM算法得到的参数估计序列Θ(i)的收敛值Θ*是L(Θ)的稳定点。

三、EM算法在高斯混合模型学习 中的应用

∞高斯混合模型:

∞ 概率分布模型;
$$P(y|\theta) = \sum_{k=1}^{K} \alpha_k \phi(y|\theta_k)$$

$$\infty$$
系数: $\alpha_k \ge 0$, $\sum_{k=1}^K \alpha_k = 1$

≫高斯分布密度:
$$\phi(y|\theta_k)$$
 $\theta_k = (\mu_k, \sigma_k^2)$

≫第K个分模型:
$$\phi(y|\theta_k) = \frac{1}{\sqrt{2\pi\sigma_k}} \exp\left(-\frac{(y-\mu_k)^2}{2\sigma_k^2}\right)$$

可任意高斯模型

高斯混合模型参数估计的EM算法

∞假设观测数据y,,y₂,....y_N由高斯混合模型生成:

$$P(y \mid \theta) = \sum_{k=1}^{K} \alpha_k \phi(y \mid \theta_k)$$

$$\theta = (\alpha_1, \alpha_2, \dots, \alpha_K; \theta_1, \theta_2, \dots, \theta_K)$$

- ∞用EM算法估计参数;
- ∞ 1、明确隐变量,写出完全数据的对数似然函数: ∞ 设想观测数据yi是依概率 a_k 选择第k个高斯分模型 $\phi(y | \theta_k)$ 生成,隐变量

$$\gamma_{jk} = \begin{cases} 1, & \text{第 } j \land \text{观测来自第 } k \land \text{分模型} \\ 0, & \text{否则} \end{cases}$$

≥1、明确隐变量,写出完全数据的对数似然函数:

$$\infty$$
完全数据: $(y_j, \gamma_{j1}, \gamma_{j2}, \cdots, \gamma_{jK})$, $j = 1, 2, \cdots, N$

記録:
$$P(y, \gamma | \theta) = \prod_{j=1}^{N} P(y_j, \gamma_{j1}, \gamma_{j2}, \dots, \gamma_{jK} | \theta)$$

$$= \prod_{k=1}^{K} \prod_{j=1}^{N} \left[\alpha_k \phi(y_j | \theta_k) \right]^{\gamma_{jk}}$$

$$= \prod_{k=1}^{K} \alpha_k^{n_k} \prod_{j=1}^{N} \left[\phi(y_j | \theta_k) \right]^{\gamma_{jk}}$$

$$= \prod_{k=1}^{K} \alpha_k^{n_k} \prod_{j=1}^{N} \left[\phi(y_j | \theta_k) \right]^{\gamma_{jk}}$$

$$= \prod_{k=1}^{K} \alpha_k^{n_k} \prod_{j=1}^{N} \left[\frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{(y_j - \mu_k)^2}{2\sigma_k^2}\right) \right]^{\gamma_{jk}}$$

$$n_k = \sum_{j=1}^N \gamma_{jk}$$

$$\sum_{k=1}^K n_k = N$$

≥1、明确隐变量,写出完全数据的对数似然函数:

$$\log P(y, \gamma \mid \theta) = \sum_{k=1}^{K} n_k \log \alpha_k + \sum_{j=1}^{N} \gamma_{jk} \left[\log \left(\frac{1}{\sqrt{2\pi}} \right) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2 \right]$$

≥2、EM算法的E步,确定Q函数

$$Q(\theta, \theta^{(i)}) = E[\log P(y, \gamma | \theta) | y, \theta^{(i)}]$$

$$= E\left\{ \sum_{k=1}^{K} n_k \log \alpha_k + \sum_{j=1}^{N} \gamma_{jk} \left[\log \left(\frac{1}{\sqrt{2\pi}} \right) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2 \right] \right\}$$

$$= \sum_{k=1}^{K} \left\{ \sum_{j=1}^{N} (E\gamma_{jk}) \log \alpha_k + \sum_{j=1}^{N} (E\gamma_{jk}) \left[\log \left(\frac{1}{\sqrt{2\pi}} \right) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2 \right] \right\}$$

需要计算 $E(\gamma_{ik}|y,\theta)$, 记为 $\hat{\gamma}_{ik}$

≫第j个观测数据来自第k个分模型的概率,称为分模型k 对观测数据y_i的响应度。

应用

≥2、EM算法的E步,确定Q函数

$$\hat{\gamma}_{jk} = E(\gamma_{jk} \mid y, \theta) = P(\gamma_{jk} = 1 \mid y, \theta)$$

$$= \frac{P(\gamma_{jk} = 1, y_j \mid \theta)}{\sum_{k=1}^{K} P(\gamma_{jk} = 1, y_j \mid \theta)}$$

$$= \frac{P(y_j \mid \gamma_{jk} = 1, \theta) P(\gamma_{jk} = 1 \mid \theta)}{\sum_{k=1}^{K} P(y_j \mid \gamma_{jk} = 1, \theta) P(\gamma_{jk} = 1 \mid \theta)}$$

$$= \frac{\alpha_k \phi(y_j \mid \theta_k)}{\sum_{k=1}^{K} \alpha_k \phi(y_j \mid \theta_k)}, \quad j = 1, 2, \dots, N; \quad k = 1, 2, \dots, K$$

≥2、EM算法的E步,确定Q函数

将
$$\hat{\gamma}_{jk} = E\gamma_{jk}$$
 及 $n_k = \sum_{i=1}^N E\gamma_{jk}$ 代入

$$Q(\theta, \theta^{(i)}) = \sum_{k=1}^{K} n_k \log \alpha_k + \sum_{k=1}^{N} \hat{\gamma}_{jk} \left[\log \left(\frac{1}{\sqrt{2\pi}} \right) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2 \right]$$

应用

≥3、确定EM算法的M步:

$$\mathfrak{P}$$
 求: $\theta^{(i+1)} = \arg\max_{\theta} Q(\theta, \theta^{(i)})$

$$\mathbb{R} \hat{\mu}_k, \hat{\sigma}_k^2 \mathcal{D} \hat{\alpha}_k, k = 1, 2, \cdots, K, 表示 \theta^{(i+1)}$$

≫ 采用求导的方法:

$$\hat{\mu}_k = rac{\displaystyle\sum_{j=1}^N \hat{\gamma}_{jk} y_j}{\displaystyle\sum_{j=1}^N \hat{\gamma}_{jk}} \qquad \hat{\sigma}_k^2 = rac{\displaystyle\sum_{j=1}^N \hat{\gamma}_{jk} (y_j - \mu_k)^2}{\displaystyle\sum_{j=1}^N \hat{\gamma}_{jk}} \qquad \hat{lpha}_k = rac{\displaystyle\sum_{j=1}^N \hat{\gamma}_{jk}}{N}$$

高斯混合模型参数估计的EM算法

≫输入:观测数据y,,y₂,...y_N,高斯混合模型

∞输出: 高斯混合模型参数

≥1、设定初始值开始迭代

≥2、E步,响应度计算

$$\hat{\gamma}_{jk} = \frac{\alpha_k \phi(y_j | \theta_k)}{\sum_{k=1}^{K} \alpha_k \phi(y_j | \theta_k)}$$

高斯混合模型参数估计的EM算法

≫输入:观测数据y,,y₂,...y_N,高斯混合模型

∞输出: 高斯混合模型参数

≥3、M步, 计算新一轮迭代的模型参数:

$$\hat{\mu}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} y_j}{\sum_{j=1}^N \hat{\gamma}_{jk}} \qquad \hat{\sigma}_k^2 = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} y_j}{\sum_{j=1}^N \hat{\gamma}_{jk}}$$

$$\hat{\alpha}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk}}{N}$$

№4、重复2,3步直到收敛

四、EM算法的推广

- ∞EM算法可以解释为:
- ≫F函数的极大---极大算法(maximization –maximization algorithm)
- 応文期望极大(Generalization Expectation Maximization. GEM)

≫F函数:

∞假设隐变量数据**Z**的概率分布为 $\tilde{P}(Z)$,定义分布 \tilde{P} 与参数 θ 的函数 $F(\tilde{P},\theta)$:

$$F(\tilde{P}, \theta) = E_{\tilde{P}}[\log P(Y, Z \mid \theta)] + H(\tilde{P})$$

>>>熵:

$$H(\tilde{P}) = -E_{\tilde{P}} \log \tilde{P}(Z)$$

∞F函数是θ的连续函数,重要性质:

pprox 这时的 $ilde{P}_{m{ heta}}$

$$\tilde{P}_{\theta}(Z) = P(Z \mid Y, \theta)$$

03

 ∞ 并且 \tilde{P}_{θ} 随 θ 连续变化。

验证明:对于固定的θ,拉格朗日函数方法对最优化问题 求 $\tilde{P}(Z)$,

$$L = E_{\tilde{P}} \log P(Y, Z \mid \theta) - E_{\tilde{P}} \log \tilde{P}(Z) + \lambda \left(1 - \sum_{Z} \tilde{P}(Z) \right)$$

≫对
$$\tilde{P}(Z)$$
 求偏导: $\frac{\partial L}{\partial \tilde{P}(Z)} = \log P(Y, Z | \theta) - \log \tilde{P}(Z) - 1 - \lambda$

🔊令偏导为o:
$$\lambda = \log P(Y, Z | \theta) - \log \tilde{P}_{\theta}(Z) - 1$$

$$\mathfrak{P}(Y,Z|\theta) = e^{1+\lambda}$$

由假设 $P(Y,Z|\theta)$ 是 θ 的连续函数,得到 \tilde{P}_{θ} 是 θ 的连续函数.

∞引理9.2:

若 $\tilde{P}_{\theta}(Z) = P(Z \mid Y, \theta)$, 则 $F(\tilde{P}, \theta) = \log P(Y \mid \theta)$

∞定理9.3:

砂 $L(\theta) = \log P(Y|\theta)$ 为观测数据的对数似然数 $\theta^{(i)}$, $i = 1, 2, \cdots$ 为EM算法得到的参数估计序列,F函数 $F(\tilde{P},\theta)$,如果 $F(\tilde{P},\theta)$ 在 \tilde{P}^* 和 θ^* 有局部极大值,那么 $L(\theta)$ 也在 θ^* 有局部极大值,类似地,如果 $F(\tilde{P},\theta)$ 在 \tilde{P}^* 和 θ^* 达到全局最大值,那么 $L(\theta)$ 也在 θ^* 达到全局最大值。

证明: 由定理9.1,9.2

 $L(\theta) = \log P(Y|\theta) = F(\tilde{P}_{\alpha}, \theta)$ 对任意 θ 成立;特别的:对于使 $F(\tilde{P}, \theta)$ 达到极大的参数 θ ,

$$L(\theta^*) = F(\tilde{P}_{\theta^*}, \theta^*) = F(\tilde{P}^*, \theta^*)$$

为了证明 θ^* 是 $L(\theta)$ 的极大点

需要证明不存在接近 θ^* 的点 θ^{**} ,使 $L(\theta^{**}) > L(\theta^*)$.

假如存在这样的点 θ^{**} ,那么应有 $F(\tilde{P}^{**},\theta^{**})>F(\tilde{P}^{*},\theta^{*})$,

这里 $\tilde{P}^{**} = \tilde{P}_{\theta^{**}}$ 但因 \tilde{P}_{θ} 是随 θ 连续变化的, \tilde{P}^{**} 应接近 \tilde{P}^{*} ,

这与 \tilde{P}^* 和 θ^* 是 $F(\tilde{P},\theta)$ 的局部极大点的假设类似可以证明关于全局最大值的结论

定理9.4:

EM算法的一次迭代可由F函数的极大----极大算法实现。 设 $\theta^{(i)}$ 为第i次迭代参数 θ 的估计, $\tilde{P}^{(i)}$ 为第i次迭代函数 \tilde{P} 的估计 在第i+1次迭代的两步为

- (1) 对固定的 $\theta^{(i)}$,求 $\tilde{P}^{(i+1)}$ 使 $F(\tilde{P},\theta^{(i)})$ 极大化;
- (2) 对固定的 $\tilde{P}^{(i+1)}$, 求 $\theta^{(i+1)}$ 使 $F(\tilde{P}^{(i+1)},\theta)$ 极大化.

定理9.4:

EM算法的一次迭代可由F函数的极大----极大算法实现。证明:

(1) 由引理 9.1, 对于固定的 $\theta^{(i)}$,

$$\tilde{P}^{(i+1)}(Z) = \tilde{P}_{\theta^{(i)}}(Z) = P(Z|Y,\theta^{(i)})$$
 使 $F(\tilde{P},\theta^{(i)})$ 极大化. 此时
$$F(\tilde{P}^{(i+1)},\theta) = E_{\tilde{p}^{(i+1)}}[\log P(Y,Z|\theta)] + H(\tilde{P}^{(i+1)})$$

$$= \sum_{Z} \log P(Y,Z|\theta)P(Z|Y,\theta^{(i)}) + H(\tilde{P}^{(i+1)})$$

由 $Q(\theta, \theta^{(i)})$ 的定义

$$F(\tilde{P}^{(i+1)},\boldsymbol{\theta}) = Q(\boldsymbol{\theta},\boldsymbol{\theta}^{(i)}) + H(\tilde{P}^{(i+1)})$$

定理9.4:

EM算法的一次迭代可由F函数的极大----极大算法实现。证明:

(2) 固定 $ilde{P}^{(i+1)}$,求 $heta^{(i+1)}$ 使 $F(ilde{P}^{(i+1)}, heta)$ 极大化.得到

$$\theta^{(i+1)} = \arg\max_{\theta} F(\tilde{P}^{(i+1)}, \theta) = \arg\max_{\theta} Q(\theta, \theta^{(i)})$$

通过以上两步完成了EM算法的一次迭代,由EM算法与F函数的极大---极大算法得到的参数估计序列 θ^0 , $i=1,2,\cdots$,是一致的。

算法 9.3 (GEM 算法 1)

输入:观测数据, F函数;

输出:模型参数.

- (1) 初始化参数 $\theta^{(0)}$, 开始迭代
- (2)第i+1次迭代,第1步:记 $\theta^{(i)}$ 为参数 θ 的估计值, $\tilde{P}^{(i)}$ 为函数 \tilde{P} 的估计.求 $\tilde{P}^{(i+1)}$ 使 \tilde{P} 极大化 $F(\tilde{P},\theta^{(i)})$
- (3) 第2步: 求 $\theta^{(i+1)}$ 使 $F(\tilde{P}^{(i+1)},\theta)$ 极大化
- (4) 重复(2)和(3),直到收敛.

问题和方法:有时求 $Q(\theta, \theta^{(i)})$ 的极大化是很困难的通过:找 $\theta^{(i+1)}$ 使得 $Q(\theta^{(i+1)}, \theta^{(i)}) > Q(\theta^{(i)}, \theta^{(i)})$

算法 9.4 (GEM 算法 2)

输入:观测数据, Q函数;

输出:模型参数.

- (1) 初始化参数 $\theta^{(0)}$, 开始迭代
- (2) 第i+1次迭代,第1步:记 $\theta^{(i)}$ 为参数 θ 的估计值,

计算
$$Q(\theta, \theta^{(i)}) = E_Z[\log P(Y, Z \mid \theta) \mid Y, \theta^{(i)}]$$
$$= \sum_{Z} P(Z \mid Y, \theta^{(i)}) \log P(Y, Z \mid \theta)$$

(3) 第2步: 求 θ⁽ⁱ⁺¹⁾ 使

$$Q(\boldsymbol{\theta}^{(i+1)}, \boldsymbol{\theta}^{(i)}) > Q(\boldsymbol{\theta}^{(i)}, \boldsymbol{\theta}^{(i)})$$

(4) 重复(2)和(3),直到收敛.

≥3当参数θ的维数为d大于等于2时,可采用一种特殊的 GEM算法,算法的M步分解为d次条件极大化,每次只改变参数向量的一个分量,其余分量不改变。

算法 9.5 (GEM 算法 3)

输入:观测数据, Q函数;

输出:模型参数.

(1) 初始化参数 $\theta^{(0)} = (\theta_1^{(0)}, \theta_2^{(0)}, \cdots, \theta_d^{(0)})$, 开始迭代

(2) 第i+1次迭代,第1步: 记 $\theta^{(i)} = (\theta_1^{(i)}, \theta_2^{(i)}, \cdots, \theta_d^{(i)})$

为参数 $\theta = (\theta_1, \theta_2, \dots, \theta_d)$ 的估计值,计算

$$Q(\theta, \theta^{(i)}) = E_Z[\log P(Y, Z \mid \theta) \mid Y, \theta^{(i)}]$$
$$= \sum_{Z} P(Z \mid y, \theta^{(i)}) \log P(Y, Z \mid \theta)$$

(3) 第2步: 进行d次条件极大化:

首先,在 $\theta_2^{(i)}$,…, $\theta_k^{(i)}$ 保持不变的条件下求使 $Q(\theta,\theta^{(i)})$ 达到极大的 $\theta_1^{(i+1)}$;

然后,在 $\theta_i = \theta_i^{(i+1)}$, $\theta_i = \theta_i^{(i)}$, $j = 3, 4, \cdots, k$ 的条件下求使 $Q(\theta, \theta^{(i)})$ 达到极大的 $\theta_2^{(i+1)}$

如此继续,经过d次条件极大化,得到 $\theta^{(i+1)} = (\theta_1^{(i+1)}, \theta_2^{(i+1)}, \cdots, \theta_s^{(i+1)})$

使得 $Q(\theta^{(i+1)}, \theta^{(i)}) > Q(\theta^{(i)}, \theta^{(i)})$

(4) 重复(2)和(3),直到收敛.

Q & A