## 第十章

# 隐马尔科夫模型

袁春 清华大学深圳研究生院 李航 华为诺亚方舟实验室

# 目录

- 1. 隐马尔科夫模型的基本概念
- 2. 概率计算算法
- 3. 学习算法
- 4. 预测算法

### 一、隐马尔科夫模型的基本概念

- ∞隐马尔科夫模型的定义
- ∞观测序列的生成过程
- ∞应马尔科夫模型的3个基本问题

## 隐马尔科夫模型的定义

- ∞隐马尔可夫模型是关于时序的概率模型;
- ₩描述由一个隐藏的马尔可夫链随机生成不可观测的状态 随机序列(state sequence),再由各个状态生成一个观测 而产生观测随机序列(observation sequence)的过程,序 列的每一个位置又可以看作是一个时刻。

#### 恕组成

- ∞初始概率分布
- 80状态转移概率分布
- ∞观测概率分布
- ∞Q: 所有可能状态的集合
- ∞V: 所有可能观测的集合

∞I:长度为T的状态序列

$$Q = \{q_1, q_2, \dots, q_N\}$$
,  $V = \{v_1, v_2, \dots, v_M\}$ 

∞O: 对应的观测序列

$$I = (i_1, i_2, \dots, i_T), \quad O = (o_1, o_2, \dots, o_T)$$

20组成

∞A: 状态转移概率矩阵

$$A = \left[ a_{ij} \right]_{N \times N}$$

$$a_{ij} = P(i_{i+1} = q_j | i_i = q_i), \quad i = 1, 2, \dots, N; \quad j = 1, 2, \dots, N$$

:时刻t处于状态q,的条件下在时刻t+1转移到状态q,的概率

∞组成

∞B: 观测概率矩阵

$$B = \left[b_j(k)\right]_{N \times M}$$

$$b_j(k) = P(o_i = v_k | i_i = q_j), \quad k = 1, 2, \dots, M; \quad j = 1, 2, \dots, N$$

在时刻t处于状态 $q_j$ 的条件下生成观测 $v_k$ 的概率  $\infty$   $\pi$  初始状态概率向量

$$\pi_i = P(i_1 = q_i), \quad i = 1, 2, \dots, N$$

时刻t=1处于状态 $q_i$ 的概率

**∞三要素** 

$$\lambda = (A, B, \pi)$$

∞两个基本假设

∞齐次马尔科夫性假设,隐马尔可分链t的状态只和t-1状态 有关:

$$P(i_t | i_{t-1}, o_{t-1}, \dots, i_1, o_1) = P(i_t | i_{t-1}), \quad t = 1, 2, \dots, T$$

∞观测独立性假设,观测只和当前时刻状态有关;

$$P(o_t \mid i_T, o_T, i_{T-1}, o_{T-1}, \dots, i_{t+1}, o_{t+1}, i_t, i_{t-1}, o_{t-1}, \dots, i_t, o_t) = P(o_t \mid i_t)$$

# 例:盒子和球模型

≫盒子: 1 2 3 4

**20**红球: 5 3 6 8

∞ 白球: 5 7 4 2

#### ∞转移规则:

- ∞盒子1 下一个 盒子2
- ∞盒子2或3 下一个 o.4 左, o.6右
- ∞盒子4 下一个 o.5 自身, o.5盒子3
- ≥ 重复5次: O={红,红,白,白,红}

# 例:盒子和球模型

≫状态集合: Q={盒子1, 盒子2, 盒子3, 盒子4}, N=4

∞观测集合: V={红球, 白球} M=2

∞初始化概率分布:

≫状态转移矩阵:  $\pi = (0.25, 0.25, 0.25, 0.25)^{T}$  观测矩阵:

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0.4 & 0 & 0.6 & 0 \\ 0 & 0.4 & 0 & 0.6 \\ 0 & 0 & 0.5 & 0.5 \end{bmatrix}$$

$$B = \begin{bmatrix} 0.5 & 0.5 \\ 0.3 & 0.7 \\ 0.6 & 0.4 \\ 0.8 & 0.2 \end{bmatrix}$$

# 观测序列的生成过程

#### 算法 10.1 (观测序列的生成)

输入: 隐马尔可夫模型  $\lambda = (A, B, \pi)$ , 观测序列长度 T;

输出: 观测序列 $O = (o_1, o_2, \dots, o_T)$ .

- (1) 按照初始状态分布 $\pi$ 产生状态 $i_1$
- (3) 按照状态i, 的观测概率分布 $b_i$ , (k) 生成 $o_i$
- (4) 按照状态  $i_i$  的状态转移概率分布  $\{a_{i,i_{+1}}\}$  产生状态  $i_{i+1}$  ,  $i_{i+1}=1,2,\cdots,N$
- (5) 令t=t+1; 如果t < T, 转步(3); 否则, 终止

### 隐马尔科夫模型的三个基本问题

- ≥1、概率计算问题
- ∞ 给定:

$$\mathfrak{D}$$
 计算:  $\lambda = (A, B, \pi) \quad O = (o_1, o_2, \dots, o_T)$ 

- **≥>2、学习问题** P(O|1)
- **20** 已知:

$$\infty$$
 估计:  $O=(o_1,o_2,\cdots,o_T)$  最大

$$\mathfrak{S}_3$$
、预测问题  $\lambda = (A, B, \pi)$   $P(O | \lambda)$ 

- ≥ 已知:
- x: 使  $\lambda = (A, B, \pi)$  最大的状态序列  $O = (o_1, o_2, \dots, o_T)$  P(I | O)  $I = (i_1, i_2, \dots, i_T)$

## 概率计算方法

∞直接计算法

∞给定模型:

和观测概率:

∞计算:

$$\lambda = (A, B, \pi)$$

$$O = (o_1, o_2, \dots, o_T)$$

**∞**最直接的*P(0|1)* 

∞列举所有可能的长度为T状态序列

 $\infty$ 求各个状态序列I与观测序列  $I = (i_1, i_2, \dots, i_r)$ 联合概率

$$I = (i_1, i_2, \dots, i_r)$$
联合概率

∞然后对所有可能的状态序列: $O = (o_1, o_2, \dots, o_r)$  $P(O,I|\lambda)$ 

 $P(O|\lambda)$ 

## 二、概率计算算法

- ∞直接计算法
- ∞前向算法
- ∞后向算法
- ∞一些概率与期望值的计算

## 概率计算方法

∞直接计算法

$$P(O,I \mid \lambda) = P(O \mid I,\lambda)P(I \mid \lambda)$$
  $= \pi_{i_1}b_{i_1}(o_1)a_{i_1i_2}b_{i_2}(o_2)\cdots a_{i_{r-1}i_r}b_{i_r}(o_r)$ 运:

$$P(O \mid \lambda) = \sum_{i_1, i_2, \dots, i_T} P(O \mid I, \lambda) P(I \mid \lambda)$$

$$= \sum_{i_1, i_2, \dots, i_T} \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \cdots a_{i_{T-1} i_T} b_{i_T}(o_T)$$

复杂度

 $O(TN^T)$ 

# 前向算法

∞前向概率定义:给定隐马尔科夫模型λ,定义到时刻t部分观测序列为: ٩,•2,···,•4,且状态为qi的概率为前向概率,

记作:  $\alpha_i(i) = P(o_1, o_2, \dots, o_t, i_t = q_i \mid \lambda)$ 

算法 10.2 (观测序列概率的前向算法)

输入: 隐马尔可夫模型 A, 观测序列 O;

输出:观测序列概率  $P(O | \lambda)$ .

 $\omega$ 初值:  $\alpha_{\scriptscriptstyle 1}(i) = \pi_i b_i(o_{\scriptscriptstyle 1})$ ,  $i = 1, 2, \dots, N$ 

验递推:  $\alpha_{t+1}(i) = \left[\sum_{j=1}^{N} \alpha_{t}(j) a_{ji}\right] b_{i}(o_{t+1}), \quad i = 1, 2, \dots, N$ 

 $P(O \mid \lambda) = \sum_{i=1}^{N} \alpha_{T}(i)$ 

# 前向算法

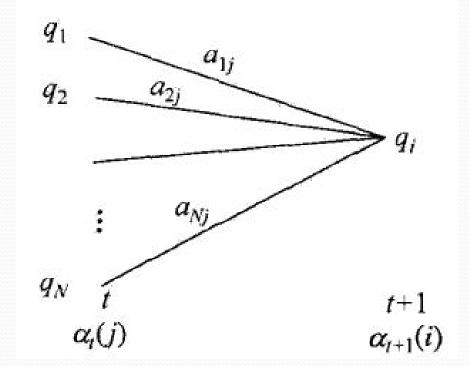
∞因为:

$$\alpha_T(i) = P(o_1, o_2, \dots, o_T, i_T = q_i \mid \lambda)$$

≫所以:

$$P(O \mid \lambda) = \sum_{i=1}^{N} \alpha_{T}(i)$$

∞递推:

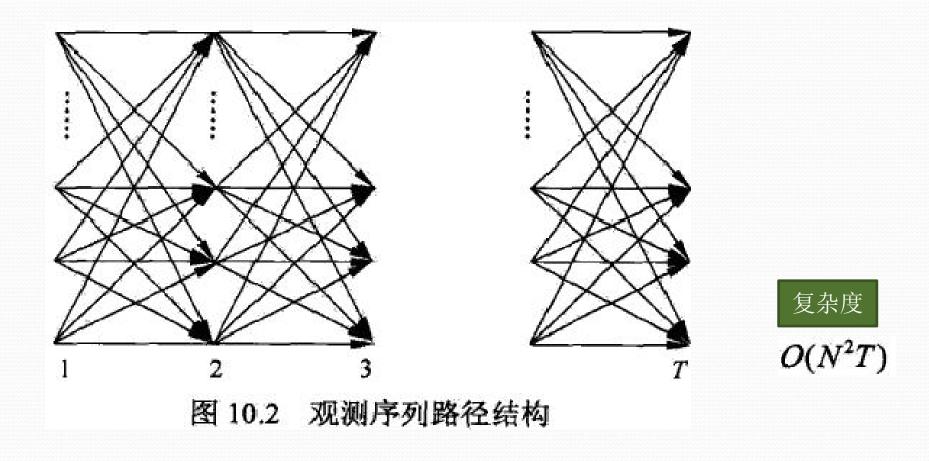


复杂度

 $O(N^2T)$ 

## 前向算法

≫减少计算量的原因在于每一次计算,直接引用前一个时刻的计算结果,避免重复计算。



例:

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \boldsymbol{\pi} = (0.2, 0.4, 0.4)^{\mathrm{T}}$$

设T=3, O=(红, 白, 红), 试用前向算法计算 $P(O|\lambda)$ 

### 解 按照算法 10.2

(1) 计算初值

$$\alpha_1(1) = \pi_1 b_1(o_1) = 0.10$$
 $\alpha_1(2) = \pi_2 b_2(o_1) = 0.16$ 
 $\alpha_1(3) = \pi_3 b_3(o_1) = 0.28$ 

例:

### (2) 递推计算

$$\alpha_{2}(1) = \left[\sum_{i=1}^{3} \alpha_{1}(i)a_{i1}\right]b_{1}(o_{2}) = 0.154 \times 0.5 = 0.077$$

$$\alpha_{2}(2) = \left[\sum_{i=1}^{3} \alpha_{1}(i)a_{i2}\right]b_{2}(o_{2}) = 0.184 \times 0.6 = 0.1104$$

$$\alpha_{2}(3) = \left[\sum_{i=1}^{3} \alpha_{1}(i)a_{i3}\right]b_{3}(o_{2}) = 0.202 \times 0.3 = 0.0606$$

$$\alpha_{3}(1) = \left[\sum_{i=1}^{3} \alpha_{2}(i)a_{i1}\right]b_{1}(o_{3}) = 0.04187$$

$$\alpha_{3}(2) = \left[\sum_{i=1}^{3} \alpha_{2}(i)a_{i2}\right]b_{2}(o_{3}) = 0.03551$$

$$\alpha_{3}(3) = \left[\sum_{i=1}^{3} \alpha_{2}(i)a_{i3}\right]b_{3}(o_{3}) = 0.05284$$

### 例:

(3) 终止

$$P(O \mid \lambda) = \sum_{i=1}^{3} \alpha_{3}(i) = 0.13022$$

# 后向算法

≥>定义10.3 后向概率: 给定隐马尔科夫模型λ, 定义在时刻t状态为qi的条件下, 从t+1到T的部分观测序列为: 的概率为后向概率, 记作:

$$o_{t+1}, o_{t+2}, \cdots, o_T$$

$$\beta_{t}(i) = P(o_{t+1}, o_{t+2}, \dots, o_{t} | i_{t} = q_{t}, \lambda)$$

可以用递推的方法求得后向概率  $\beta_i(i)$  及观测序列概率  $P(O|\lambda)$ 

# 后向算法

### 算法 10.3 (观测序列概率的后向算法)

输入: 隐马尔可夫模型 $\lambda$ , 观测序列O;

输出:观测序列概率  $P(O|\lambda)$ .

(1)

$$\beta_T(i) = 1$$
,  $i = 1, 2, \dots, N$ 

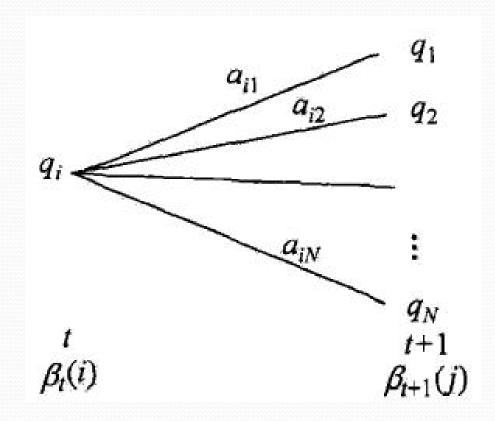
(2) 对 $t = T - 1, T - 2, \dots, 1$ 

$$\beta_{i}(i) = \sum_{j=1}^{N} a_{ij} b_{j}(o_{i+1}) \beta_{i+1}(j), \quad i = 1, 2, \dots, N$$

(3)

$$P(O | \lambda) = \sum_{i=1}^{N} \pi_i b_i(o_1) \beta_1(i)$$

# 后向算法



≫前向后向统一写为: (t=1和t=T-1分别对应)

$$P(O \mid \lambda) = \sum_{i=1}^{N} \sum_{j=1}^{N} \alpha_{t}(i) a_{ij} b_{j}(o_{t+1}) \beta_{t+1}(j), \quad t = 1, 2, \dots, T-1$$

## 些概率和期望值的计算

1. 给定模型 λ 和观测 O, 在时刻 t 处于状态 q, 的概率.

记 
$$\gamma_t(i) = P(i_t = q_i \mid O, \lambda)$$

$$\gamma_t(i) = P(i_t = q_i \mid O, \lambda) = \frac{P(i_t = q_i, O \mid \lambda)}{P(O \mid \lambda)}$$

$$\alpha_{i}(i)\beta_{i}(i) = P(i_{i} = q_{i}, O \mid \lambda)$$

$$\gamma_{t}(i) = \frac{\alpha_{t}(i)\beta_{t}(i)}{P(O|\lambda)} = \frac{\alpha_{t}(i)\beta_{t}(i)}{\sum_{j=1}^{N} \alpha_{t}(j)\beta_{t}(j)}$$

## 些概率和期望值的计算

2. 给定模型 $\lambda$ 和观测O,在时刻t处于状态 $q_i$ 且在时刻t+1处于状态 $q_j$ 的概率. 记

$$\xi_{t}(i,j) = P(i_{t} = q_{i}, i_{t+1} = q_{j} \mid O, \lambda)$$

通过前向后向概率计算:

$$\xi_{t}(i,j) = \frac{P(i_{t} = q_{i}, i_{t+1} = q_{j}, O \mid \lambda)}{P(O \mid \lambda)} = \frac{P(i_{t} = q_{i}, i_{t+1} = q_{j}, O \mid \lambda)}{\sum_{i=1}^{N} \sum_{j=1}^{N} P(i_{t} = q_{i}, i_{t+1} = q_{j}, O \mid \lambda)}$$

$$P(i_{t} = q_{i}, i_{t+1} = q_{j}, O | \lambda) = \alpha_{t}(i)a_{ij}b_{j}(o_{t+1})\beta_{t+1}(j)$$

$$\xi_{t}(i,j) = \frac{\alpha_{t}(i)a_{ij}b_{j}(o_{t+1})\beta_{t+1}(j)}{\sum_{i=1}^{N}\sum_{j=1}^{N}\alpha_{t}(i)a_{ij}b_{j}(o_{t+1})\beta_{t+1}(j)}$$

# 一些概率和期望值的计算

- 3. 将 $\gamma_i(i)$ 和 $\xi_i(i,j)$ 对各个时刻t求和,可以得到一些有用的期望值:
- (1) 在观测 O 下状态 i 出现的期望值

$$\sum_{t=1}^{T} \gamma_t(i)$$

(2) 在观测 O 下由状态 i 转移的期望值

$$\sum_{t=1}^{T-1} \gamma_t(i)$$

(3) 在观测O下由状态i转移到状态j的期望值

$$\sum_{t=1}^{T-1} \xi_t(i,j)$$

## 三、学习算法

- ∞监督学习方法
- ≥ Baum-Welch 算法
- ≫Baum-Welch模型参数估计公式

# 学习算法

#### ∞监督学习方法:

 $\infty$ 假设训练数据是包括观测序列O和对应的状态序列I  $\{(O_1,I_1),(O_2,I_2),\cdots,(O_s,I_s)\}$ 

砂可以利用极大似然估计法来估计隐马尔可夫模型参数。

#### ≥ 非监督学习方法:

- ∞假设训练数据只有S个长度为T的观测序{O1,O2,...Os},
- ∞采用Baum-Welch算法

## 监督学习方法

∞已知:

- ≫设样本中时刻t处于状态i,时刻t+1转移到状态j的频数为A<sub>ij</sub>,那么状态转移概率a<sub>ij</sub>的估计是:

$$\hat{a}_{ij} = \frac{A_{ij}}{\sum_{j=1}^{N} A_{ij}}$$
,  $i = 1, 2, \dots, N$ ;  $j = 1, 2, \dots, N$ 

# 监督学习方法

#### ∞已知:

 $\infty_2$ 、观测 $\{(O_i,I_i),(O_2,I_2),...,(O_s,I_s)\}$ 设样本中状态为j并观测为k的频数是 $B_i(k)$ ,那么状态为j观测为k的概率

$$\hat{b}_{j}(k) = \frac{B_{jk}}{\sum_{k=1}^{M} B_{jk}}, \quad j = 1, 2, \dots, N \; ; \; k = 1, 2, \dots, M$$

∞往往人工标注数据很贵

### Baum-Welch算法

- ≥>假定训练数据只包括{O1,O2,...Os},
- ※求模型参数λ=(A,B,π)
- ∞实质上是有隐变量的概率模型: EM算法

$$P(O | \lambda) = \sum_{I} P(O | I, \lambda) P(I | \lambda)$$

≥1、确定完全数据的对数似然函数

## Baum Welch算法

≥ EM的E步

求 
$$Q$$
 函数  $Q(\lambda, \overline{\lambda})$ 

$$Q(\lambda, \overline{\lambda}) = \sum_{I} \log P(O, I \mid \lambda) P(O, I \mid \overline{\lambda})$$

$$P(O,I \mid \lambda) = \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \cdots a_{i_{T-1} i_T} b_{i_T}(o_T)$$

$$Q(\lambda, \overline{\lambda}) = \sum_{I} \log \pi_{i_{I}} P(O, I \mid \overline{\lambda})$$

$$+\sum_{I}\left(\sum_{t=1}^{T-1}\log a_{i_{t}i_{t+1}}\right)P(O,I\mid\overline{\lambda})+\sum_{I}\left(\sum_{t=1}^{T}\log b_{i_{t}}(o_{t})\right)P(O,I\mid\overline{\lambda})$$

### Baum Welch算法

 $ω_3$ 、EM算法的M 步,极大化 \_\_\_\_ 求模型参数A,B,π  $O(\lambda,\lambda)$ 第一项:

第一项: 
$$\sum_{I} \log \pi_{i_0} P(O, I | \bar{\lambda}) = \sum_{i=1}^{N} \log \pi_{i} P(O, i_i = i | \bar{\lambda})$$
 由约束条件: 
$$\sum_{I=1}^{N} \pi_{i} = 1$$
 利用拉格朗日乘子:

$$\sum_{i=1}^{N} \log \pi_{i} P(O, i_{1} = i \mid \overline{\lambda}) + \gamma \left( \sum_{i=1}^{N} \pi_{i} - 1 \right)$$
求偏导数,并结果力O

03

$$\frac{\partial}{\partial \pi_i} \left[ \sum_{i=1}^N \log \pi_i P(O, i_1 = i \mid \overline{\lambda}) + \gamma \left( \sum_{i=1}^N \pi_i - 1 \right) \right] = 0$$

₩得:

$$P(O, i_1 = i \mid \overline{\lambda}) + \gamma \pi_i = 0 \qquad \gamma = -P(O \mid \overline{\lambda}) \qquad \pi_i = \frac{P(O, i_1 = i \mid \lambda)}{P(O \mid \overline{\lambda})}$$

# 学习算法 Baum Welch算法

∞3、EM算法的M 步,极大化 求A,B,π 第二项可写成:  $Q(\lambda, \overline{\lambda})$ 

$$\sum_{I} \left( \sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) P(O, I \mid \overline{\lambda}) = \sum_{t=1}^{N} \sum_{j=1}^{N} \sum_{t=1}^{T-1} \log a_{ij} P(O, i_t = i, i_{t+1} = j \mid \overline{\lambda})$$

由约束条件

₩得:

, 拉格朗日乘子法:

$$\sum_{j=1}^{N} a_{ij} = 1$$

$$T-1$$

$$a_{ij} = \frac{\sum_{t=1}^{T-1} P(O, i_t = i, i_{t+1} = j \mid \overline{\lambda})}{\sum_{t=1}^{T-1} P(O, i_t = i \mid \overline{\lambda})}$$

### Baum Welch算法

$$\sum_{I} \left( \sum_{t=1}^{T} \log b_{i_t}(o_t) \right) P(O, I \mid \overline{\lambda}) = \sum_{j=1}^{N} \sum_{t=1}^{T} \log b_{j}(o_t) P(O, i_t = j \mid \overline{\lambda})$$

由约束条件:

$$\sum_{k=1}^{M} b_j(k) = 1$$

注意,只有在 $o_i = v_k$  时 $b_j(o_i)$  对 $b_j(k)$  的偏导数才不为 0,

以 
$$I(o_t = v_k)$$
 表示. 求得
$$b_j(k) = \frac{\sum_{t=1}^T P(O, i_t = j \mid \overline{\lambda}) I(o_t = v_k)}{\sum_{t=1}^T P(O, i_t = j \mid \overline{\lambda})}$$

# 学习算法 Baum Welch算法

∞将已上得到的概率分别用 "(i), ξ,(i, i), 示:

$$a_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i,j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$

$$b_{j}(k) = \frac{\sum_{t=1,o_{j}=v_{k}}^{T} \gamma_{t}(j)}{\sum_{t=1}^{T} \gamma_{t}(j)}$$

$$\pi_i = \gamma_1(i)$$

#### 算法 10.4 (Baum-Welch 算法)

输入: 观测数据  $O = (o_1, o_2, \dots, o_T)$ ;

输出: 隐马尔可夫模型参数.

(1) 初始化

对 n=0 , 选取  $a_{ij}^{(0)}$  ,  $b_{j}(k)^{(0)}$  ,  $\pi_{i}^{(0)}$  , 得到模型  $\lambda^{(0)}=(A^{(0)},B^{(0)},\pi^{(0)})$ 

(2) 递推. 对 n=1,2,…,

$$a_{ij}^{(n+1)} = \frac{\sum_{t=1}^{T-1} \xi_t(i,j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$

$$b_j(k)^{(n+1)} = \frac{\sum_{t=1,o_i=v_k}^{T} \gamma_t(j)}{\sum_{t=1}^{T} \gamma_t(j)}$$

$$\pi_i^{(n+1)} = \gamma_1(i)$$

右端各值按观测  $O=(o_1,o_2,\cdots,o_T)$  和模型  $\lambda^{(n)}=(A^{(n)},B^{(n)},\pi^{(n)})$  计算

(3) 终止. 得到模型参数  $\lambda^{(n+1)} = (A^{(n+1)}, B^{(n+1)}, \pi^{(n+1)})$ 

# 四、预测算法

∞近似算法

∞维特比算法

### 近似算法算法

题想法: 在每个时刻t选择在该时刻最有可能出现的状态  $i_t$ , 从而得到一个状态序列  $I^* = (i_t^*, i_t^*, \dots, i_r^*)$ , 将它作为预测的结果, 在时刻t处于状态qi的概率:

∞在每一时刻t最有可能的状态是:

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{P(O \mid \lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^{N} \alpha_t(j)\beta_t(j)}$$

从而得到状态序列:  $i_i^* = \arg\max_{1 \leq i \leq N} [\gamma_i(i)], t = 1, 2, \dots, T$ 

得到的状态有可能实际不发生

$$I^* = (i_1^*, i_2^*, \cdots, i_T^*)$$

### 维特比算法

- ≫Viterbi 方法
- >> 用动态规划解概率最大路径,一个路径对应一个状态序列。
- ≥>最优路径具有这样的特性:如果最优路径在时刻t通过结点;,那么这一路径从结点; 到终点; 的部分路径,对于从; 到; 的所有可能的部分路径来说,必须是最优的。
- 彩只需从时刻t=1开始,递推地计算在时刻t状态为i的各条部分路径的最大概率,直至得到时刻t=T状态为i的各条路径的最大概率,时刻t=T的最大概率即为最优路径的概率P\*,最优路径的终结点;也同时得到。
- ≥>之后,为了找出最优路径的各个结点,从终结点开始,由后 向前逐步求得结点 ; , , , , , , , 得到最优路径

$$I^* = (i_1^*, i_2^*, \dots, i_T^*)$$

### 维特比算法

验导入两个变量δ和 $\psi$ ,定义在时刻t状态为i的所有单个路径( $i_1,i_2,\dots,i_t$ ) 中概率最大值为:

$$\delta_{t}(i) = \max_{i_{1},i_{2},\cdots,i_{t-1}} P(i_{t} = i, i_{t-1},\cdots,i_{1},o_{t},\cdots,o_{1} \mid \lambda), \quad i = 1,2,\cdots,N$$

∞由定义可得变量δ的递推公式:

$$\delta_{t+1}(i) = \max_{i_1, i_2, \dots, i_t} P(i_{t+1} = i, i_t, \dots, i_1, o_{t+1}, \dots, o_1 \mid \lambda)$$

$$= \max_{1 \le j \le N} [\delta_t(j) a_{ji}] b_i(o_{t+1}), \qquad i = 1, 2, \dots, N; \quad t = 1, 2, \dots, T - 1$$

≈定义在时刻t状态为i的所有单个路径 (4,4,···,4,1,1) 中概率最大的路径的第t-1个结点为

$$\psi_t(i) = \arg\max_{1 \leq i \leq N} [\delta_{t-1}(j)a_{ji}], \quad i = 1, 2, \dots, N$$

### Viterbi 方法

#### 算法 10.5 (维特比算法)

输入: 模型 $\lambda = (A, B, \pi)$ 和观测 $O = (o_1, o_2, \dots, o_T)$ ;

输出:最优路径 $I^* = (i_1^*, i_2^*, \dots, i_T^*)$ .

(1) 初始化

$$\delta_1(i) = \pi_i b_i(o_1)$$
,  $i = 1, 2, \dots, N$   
 $\psi_1(i) = 0$ ,  $i = 1, 2, \dots, N$ 

(2) 递推. 对  $t = 2, 3, \dots, T$ 

$$\delta_{t}(i) = \max_{1 \leq j \leq N} [\delta_{t-1}(j)a_{ji}]b_{i}(o_{t}), \qquad i = 1, 2, \dots, N$$

$$\psi_{t}(i) = \arg \max_{1 \le i \le N} [\delta_{t-1}(j)a_{ji}], \quad i = 1, 2, \dots, N$$

### Viterbi 方法

(3) 终止

$$P^* = \max_{1 \le i \le N} \delta_T(i)$$
$$i_T^* = \arg \max_{1 \le i \le N} [\delta_T(i)]$$

(4) 最优路径回溯. 对  $t = T - 1, T - 2, \dots, 1$   $i_{i}^{*} = \psi_{i+1}(i_{i+1}^{*})$ 

求得最优路径  $I^* = (i_1^*, i_2^*, \dots, i_r^*)$ 

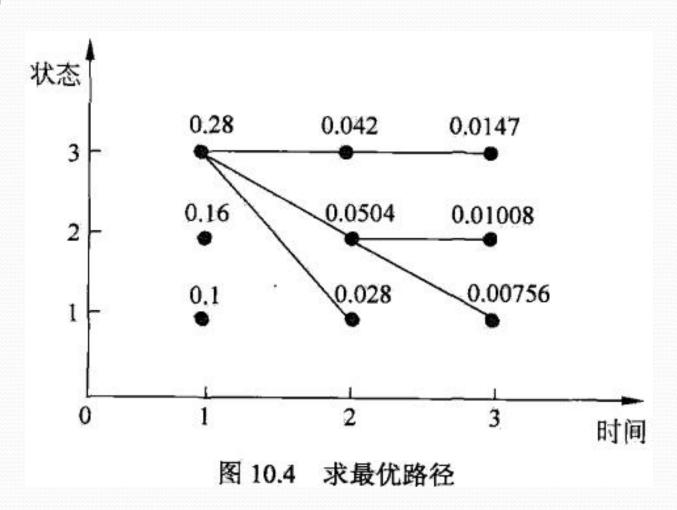
$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^{\mathrm{T}}$$

O = (红, 白, 红),试求最优状态序列,即最优路径  $I^* = (i^*, i^*_5, i^*_5)$   $\infty$ 1、初始化:在t = 1时,对每一个状态i,i = 1, 2, 3,求状态i 观测O1为红的概率,记为: $\delta(i)$ 

 $\infty$ 代入实际数据:  $\delta_1(i) = \pi_i b_i(o_1) = \pi_i b_i(\mathfrak{U})$ , i = 1,2,3

$$\delta_1(1) = 0.10$$
,  $\delta_1(2) = 0.16$ ,  $\delta_1(3) = 0.28$ 

 $记 \psi_1(i) = 0, \quad i = 1, 2, 3$ 



№2、在t=2时,对每一个状态i, i=1,2,3,求在t=1时状态为j观测O1为红并在t=2时状态为i观测O2位白的路径的最大概率,记为

$$\delta_2(i) = \max_{1 \le j \le 3} \left[ \delta_1(j) a_{ji} \right] b_i(o_2)$$

∞同时,对每个状态i,记录概率最大路径的前一个状态j

$$\psi_2(i) = \arg \max_{1 \le j \le 3} [\delta_1(j)a_{ji}], \quad i = 1, 2, 3$$

$$\delta_{2}(1) = \max_{1 \le j \le 3} [\delta_{1}(j)a_{j1}]b_{1}(o_{2})$$

$$= \max_{j} \{0.10 \times 0.5, 0.16 \times 0.3, 0.28 \times 0.2\} \times 0.5$$

$$= 0.028$$

$$\psi_{2}(1) = 3$$

$$\delta_{2}(2) = 0.0504, \quad \psi_{2}(2) = 3$$

$$\delta_{2}(3) = 0.042, \quad \psi_{2}(3) = 3$$

同样,在
$$t=3$$
时

$$\delta_{3}(i) = \max_{1 \le j \le 3} [\delta_{2}(j)a_{ji}]b_{i}(o_{3})$$

$$\psi_{3}(i) = \arg\max_{1 \le j \le 3} [\delta_{2}(j)a_{ji}]$$

$$\delta_{3}(1) = 0.00756, \quad \psi_{3}(1) = 2$$

$$\delta_{3}(2) = 0.01008, \quad \psi_{3}(2) = 2$$

$$\delta_{3}(3) = 0.0147, \quad \psi_{3}(3) = 3$$

≥>3、以P\*表示最优路径的概率:

$$P^* = \max_{1 \le i \le 3} \delta_3(i) = 0.0147$$

∞最优路径的终点是:

$$i_3^* = \arg\max_i \left[ \delta_3(i) \right] = 3$$

 $\infty_4$ 、由最优路径的终点  $\xi_1$ ,逆向找到  $\xi_2$ ,  $\xi_3$  在t=2 时,  $\xi_2 = \psi_3(\xi_1) = \psi_3(3) = 3$ 

在
$$t=1$$
时, $i_1^*=\psi_2(i_2^*)=\psi_2(3)=3$ 

≥ 于是求得最优路径,即最优状态序列:

$$I^* = (i_1^*, i_2^*, i_3^*) = (3, 3, 3)$$

# **END**

